Projeto Final

«LusoEnergia»: análise integral de consumo elétrico - do dado bruto ao fluxo em tempo real

Duração: 5 semanas (trabalho autónomo) + 3 checkpoints em aula PL **Modalidade:** grupos de 2–3
Cotação: 20 valores **Entrega:** notebook(s) + relatório + apresentação de 10 min com defesa

1. Cenário

A LusoEnergia, uma comercializadora de eletricidade, contratou o vosso grupo como equipa de análise de dados. A empresa dispõe de leituras de consumo ao minuto de habitações monitorizadas ao longo de vários anos e quer respostas em três frentes: **compreender** os padrões de consumo dos clientes, **antecipar** o consumo para planear compras de energia, e **monitorizar em tempo real** o fluxo de leituras para detetar anomalias e mudanças de regime. O vosso trabalho percorre o pipeline completo da UC, e será avaliado tanto pelo rigor técnico como pela qualidade das decisões e da comunicação.

2. Os dados

Dataset obrigatório: «Individual Household Electric Power Consumption» (UCI Machine Learning Repository) — ~2 075 259 leituras ao minuto (dez. 2006 a nov. 2010), 9 variáveis: data, hora, potência ativa e reativa globais, tensão, intensidade e 3 submedições (cozinha, lavandaria, climatização/águas quentes).

Este dataset foi escolhido porque é REAL e, por isso, hostil: datas e horas em colunas de texto separadas, valores em falta marcados com '?', períodos longos de falha de medição, unidades a exigir atenção (kW vs Wh), forte sazonalidade e volume suficiente para tornar a eficiência (vetorização!) obrigatória.

Personalização por grupo (anti-cópia): cada grupo trabalha com uma janela de 18 meses definida pela seed do grupo (soma dos números de aluno), sorteada com o código abaixo, e reporta a janela usada no relatório. As análises de grupos diferentes NÃO são comparáveis entre si.

```
import numpy as np
rng = np.random.default_rng(SOMA_DOS_NUMEROS_DE_ALUNO)
inicio = rng.choice(pd.date_range('2007-01-01', '2009-05-01', freq='MS'))
fim = inicio + pd.DateOffset(months=18)   # a vossa janela de analise
```

3. Parte I — Fundação: tipos, qualidade e sumário (M1, M2, M6)

1.1) Carregamento e tipagem correta: construir uma função `carregar_dados()` que lê o ficheiro bruto e devolve um DataFrame com índice temporal (`DatetimeIndex`), dtypes justificados variável a variável (dicionário de dados com escala de medida de Stevens para cada coluna) e sentinelas '?' convertidas. Mínimo de 5 `asserts` de validação (ex.: potências não negativas, índice único e ordenado). (2,0 val.)

1.2) Auditoria de qualidade: quantificar valores em falta por variável E por período (há dias inteiros sem leituras, encontrem-nos e visualizem-nos num calendário/heatmap temporal). Classificar o mecanismo provável (MCAR/MAR/MNAR) com argumentação, decidir e JUSTIFICAR a estratégia de tratamento, a decisão tem de ser diferente para lacunas de 1 minuto e para lacunas de 2 dias. (2,0 val.)

1.3) Sumário estatístico com juízo: para as variáveis principais, medidas de localização/dispersão adequadas à forma (justificar média vs mediana com skew), outliers pela regra 1.5×IQR E por z-score robusto (mediana/MAD), com investigação: os extremos são erros, eventos reais (ondas de frio?) ou

fraude potencial? Sumário estratificado obrigatório: consumo por hora do dia × dia da semana (pivot com n). (2,0 val.)

4. Parte II — Compreender: visualização e estrutura (M3, M4, M5)

2.1) Análise descritiva e diagnóstica: caracterizar a sazonalidade (diária, semanal, anual) com no mínimo 4 figuras «de relatório» (título-afirmação, unidades, anotações, integridade gráfica — nada de eixos truncados em barras). Pelo menos uma figura deve usar small multiples. Depois, diagnóstico: escolher UM padrão intrigante (ex.: um mês atípico, uma quebra de consumo) e investigar o porquê com drill-down, terminando com hipóteses classificadas por plausibilidade. (2,5 val.)

2.2) Perfis diários com redução de dimensão: construir a matriz de perfis — cada linha é um dia, cada coluna a média horária do consumo (24 dimensões). Padronizar, aplicar PCA, interpretar os 2–3 primeiros componentes através dos loadings («o que é um PC1 alto em linguagem de consumo?»), reportar variância explicada com scree plot, e projetar os dias em PC1×PC2 coloridos por estação do ano e por dia útil/fim de semana. Comparar com t-SNE ou UMAP (seed fixa!) e discutir o que cada projeção revela e esconde — incluindo o que NÃO se pode ler no mapa t-SNE. (3,0 val.)

5. Parte III — Antecipar: seleção de variáveis sem batota (M7)

3.1) Problema preditivo: prever o consumo total do DIA SEGUINTE (agregação diária). Construir ≥ 12 variáveis candidatas: lags (1, 2, 7 dias), médias móveis, variáveis de calendário (dia da semana, mês, feriado — pode usar a biblioteca holidays), temperatura se decidirem enriquecer com dados externos (bónus). ATENÇÃO à linha temporal: cada variável só pode usar informação disponível ANTES do dia a prever — variáveis com fuga anulam a Parte III. (2,0 val.)

3.2) Seleção comparada: aplicar um método filter (correlação/informação mútua), um wrapper (RFE) e um embedded (Lasso), TODOS dentro de um Pipeline com validação temporal (`TimeSeriesSplit` — justificar porque o KFold aleatório seria leakage aqui). Comparar os subconjuntos selecionados, avaliar um modelo simples (regressão linear) com todas vs selecionadas, e analisar a estabilidade da seleção entre folds. Concluir: que variáveis recomendam à LusoEnergia medir/manter, e porquê? (2,5 val.)

6. Parte IV — Monitorizar: o fluxo em tempo real (M8)

4.1) Replay do fluxo: processar as leituras ao minuto elemento a elemento (proibido olhar para o array completo nesta parte, exceto para verificação): média/variância globais por Welford (verificadas contra o batch), janela deslizante de 60 min e EWMA, com gráfico comparativo num dia interessante. (1,5 val.)

4.2) Drift e anomalias: aplicar ADWIN (River) ao fluxo (ou a agregados de 15 min) e interpretar as deteções face à sazonalidade — mudança de estação é drift recorrente: como distinguir de uma mudança estrutural? Construir um alarme de anomalias com z-score em janela e avaliar qualitativamente 5 alarmes: reais ou falsos? Fechar com uma recomendação operacional: que limiar e que janela aconselham à sala de controlo, considerando o custo de falsos alarmes vs anomalias perdidas? (2,5 val.)

7. Parte V — Comunicar (M1, M5, M9)

5.1) Relatório executivo (célula Markdown final ou PDF de 3–4 páginas): estrutura obrigatória «o que os dados mostram · o que sugerem · o que não permitem concluir · recomendações à LusoEnergia (uma por Parte)». Linguagem rigorosa: associação ≠ causa; previsão ≠ certeza. Incluir a figura-síntese do projeto — UMA imagem que conte a história principal. (incluído na rubrica)

5.2) Reprodutibilidade total: repositório organizado (dados brutos intocados, src/ com funções reutilizadas ≥ 3 vezes, requirements.txt com versões, README com instruções), seeds fixas em TUDO o que é aleatório, e o teste final: Restart & Run All limpo. A avaliação técnica para na primeira célula que falhar. (incluído na rubrica)

8. A pergunta livre (obrigatória)

Além do guião, cada grupo formula e responde a UMA pergunta própria sobre estes dados que considere valiosa para a empresa — é aqui que se distinguem os 18–20. Exemplos de calibre adequado: «as submedições permitem estimar o potencial de poupança com tarifas bi-horárias?», «consegue-se detetar férias/ausências automaticamente e com que fiabilidade?», «o perfil de consumo mudou de forma permanente após algum evento identificável?». A pergunta deve ser aprovada no checkpoint 2.

9. Dashboard Interativo

A LusoEnergia não quer notebooks: quer uma ferramenta que um gestor comercial e um operador da sala de controlo consigam usar sem escrever código. Esta parte transforma as vossas análises num dashboard.

Implementação:

1. *Visão geral e qualidade dos dados*: KPIs da janela do grupo (consumo médio diário, % de missing, nº de dias sem leituras).
2. *Padrões de consumo*: sazonalidade com filtros (granularidade horária/diária/mensal, intervalo de datas, variável) e a projeção PCA dos perfis diários, com *hover* que mostra a data e o tipo de dia.
3. *Previsão*: consumo previsto vs real para o dia seguinte, com o baseline, o erro por período e as variáveis selecionadas na Parte III.
4. *Monitorização*: replay do fluxo com Welford/EWMA, alarmes assinalados e **controlos interativos para a janela e o limiar do z-score**, de modo que o operador veja o efeito na quantidade de alarmes.

10. Calendário e checkpoints (obrigatórios, em aula PL)

- **Checkpoint 1 (fim da semana 1):** dados carregados e tipados, auditoria de qualidade esboçada. Sem CP1 validado, o grupo não pode prosseguir para avaliação.
- **Checkpoint 2 (fim da semana 3):** Partes I–II completas, pergunta livre aprovada, plano das Partes III–IV.
- **Checkpoint 3 (fim da semana 4):** Partes III–IV em rascunho avançado; ensaio da narrativa do relatório.
- **Entrega final (fim da semana 5):** Moodle, até às 23:59. Apresentações e defesas na semana seguinte.

11. Rubrica de avaliação (20 valores)

Critério	O que se espera
Parte I — Fundação (6 val.)	Tipagem justificada e validada (2,0) · auditoria e tratamento de missing com argumentação (2,0) · sumário e outliers com juízo (2,0).
Parte II — Compreensão (5,5 val.)	Visualização com integridade e diagnóstico fundamentado (2,5) · PCA/perfis interpretados corretamente, comparação honesta com t-SNE/UMAP (3,0).
Parte III — Predição (4,5 val.)	Engenharia de variáveis sem fuga temporal (2,0) · seleção comparada com validação temporal e

	conclusões de negócio (2,5). Leakage detetado = 0 nesta parte.
Parte IV — Fluxo (4 val.)	Processamento incremental correto e verificado (1,5) · drift/anomalias com interpretação e recomendação operacional (2,5).
Transversal (até − 4 val.)	Relatório executivo, pergunta livre, reprodutibilidade e dashboard interativo (plotly/ streamlit) apresentação não somam — SUBTRAEM se falharem: relatório fraco (−1,5), pergunta livre ausente/trivial (−1), irreprodutibilidade parcial (−1), apresentação/defesa insuficiente (−0,5).

12. Defesa e integridade

- Apresentação de 10 min (problema → 3 descobertas → recomendações) + 5 min de perguntas. Qualquer membro responde sobre qualquer célula; a nota é individualizável até ±3 valores dentro do grupo.
- IA generativa: permitida como assistente, com declaração obrigatória (onde e para quê). Código que um membro não saiba explicar na defesa anula a componente correspondente para esse membro.
- Plágio entre grupos ou de fontes externas sem citação: participação ao conselho pedagógico, nos termos regulamentares.

13. Conselhos finais

- Comecem pela leitura dos dados no dia 1 — o carregamento deste ficheiro tem armadilhas que consomem tempo (separador, '?', datas, memória: considerem dtypes explícitos e/ou parquet intermédio).
- Vetorizem: com 2 milhões de linhas, um apply mal posto transforma segundos em horas.
- Guardem tempo para o relatório: metade dos prcojetos tecnicamente bons perde valores por comunicar mal. A figura-síntese merece uma tarde.

Em caso de dúvida sobre uma decisão de análise, documentem a alternativa que rejeitaram e porquê — isso É análise de dados.